English Academic Version

AI Development Study: Year 1
Phase 1 Benchmarking of Large Language Models in Elite Physics, Mathematics, and Medical Olympiads

Author
Kirill Bulannikov
Advanced STEM & Mathematics Track (Math Vertical), Pokrovsky Kvartal School

Date
October 2026

Evaluated AI Architectures
To establish the Phase 1 baseline, the following seven state-of-the-art Large Language Model (LLM) architectures were tested:

- ChatGPT (OpenAI)
- Claude (Anthropic)
- Gemini (Google)
- DeepSeek (DeepSeek AI)
- Meta AI (Meta)
- Grok (xAI)
- Alisa AI (Yandex)

Olympiad Task Suite

Physics Suite

- TASK P-1: Water Mixing & Thermal Equilibrium (Part 1)
Two identical cups are filled with water. The first cup is full to the brim with cold water at a temperature of t_1 = 13 °C. The second cup is half-full with hot water. Water is poured from the first cup into the second cup until it is full to the brim. After the temperature becomes stable, the same amount of water is poured back into the first cup. After thermal equilibrium is reached in the first cup, this cycle is repeated several times. Heat exchange with the outside world is ignored.

What was the initial temperature t_2 of the hot water, if after the first full cycle the water temperatures in the cups differed by $\Delta t_1 = 16$ °C? Give the answer in degrees Celsius, rounded to the nearest integer.

- ⚛ TASK P-2: Water Mixing & Thermal Equilibrium (Part 2)
  Using the same conditions as in Task P-1: What will be the temperature difference Δt_3 between the two cups after the third full cycle of pouring water back and forth? Give the answer in degrees Celsius, rounded to the nearest tenth.

- ⚛ TASK P-3: Yacht Engine Speed Hypotheses
  A yacht captain was choosing a new propeller. He did a simple test. When the engine speed was (2.0 ± 0.1) thousand rpm, the yacht speed in calm weather was (6.3 ± 0.1) knots. When the engine speed was (1.4 ± 0.1) thousand rpm, the yacht speed was (4.3 ± 0.1) knots.
  Do these measurements contradict or not contradict the hypothesis that the yacht's speed is directly proportional to the engine speed? Options: 1) Contradict, 2) Do not contradict, 3) Not enough data to answer.

- ⚛ TASK P-4: Fuel Consumption Calculation
  A yacht engine can work between 1.0 thousand rpm and 3.0 thousand rpm. Fuel consumption depends on the engine speed. A graph shows that at an engine speed of N = 2.0 thousand rpm, the fuel consumption is Q = 3 liters per hour.
  Calculate the fuel consumption per 100 kilometers of travel at an engine speed of 2.0 thousand rpm. Note: 1 nautical mile = 1852 meters, and 1 knot = 1 nautical mile per hour. Assume that at 2.0 thousand rpm, the yacht moves at exactly 6.3 knots. Give the answer in liters/(100 km), rounded to the nearest integer.

- ⚛ TASK P-5: Yacht Motion Dynamics
  This extra placeholder task serves as a verification benchmark for basic multi-variable mechanical equations based on the previous system dynamics.

🖹 Mathematics Suite

- 🖩 TASK M-1: Factorial Divisibility
  Find the largest natural number n such that (7!)! is divisible by n!. Note: k! means the product 1 * 2 * 3 * ... * k.

- 🖩 TASK M-2: Store Purchases
  Sasha and Masha went to a store. Sasha bought 3 cartons of milk, 7 packs of cottage cheese, and 5 yogurts. Masha bought 2 cartons of milk, 10 packs of cottage cheese, and 6 yogurts. Sasha spent 980 rubles in total, and Masha spent 1160 rubles. What is the total combined cost of one carton of milk, one pack of cottage cheese, and one yogurt?

- 🖩 TASK M-3: Trapezoid Geometry Proof
  Inside a trapezoid ABCD with bases AD and BC, a point O is marked. It turns out that AO = BO = CO = BC and DA = DO = DC. How many degrees is angle BAO?

- ⌨ TASK M-4: Right Triangle & Angle Bisectors
  In a right-angled triangle ABC with right angle C, the height CH is drawn. Points X and Y are marked on the hypotenuse AB such that CX and CY are the angle bisectors of angles BCH and HCA, respectively. Find the length of side AB, if the perimeter of triangle ABC is 44, and the length of segment XY is 6.

🗎 Medical Suite

- TASK MED-1: Clinical Diagnosis of Acute Respiratory Symptoms
  Clinical situation: A 28-year-old man visits a doctor. He complains of a sore throat, a slightly blocked nose with clear discharge, mild weakness, and frequent sneezing. The symptoms started the previous evening after he got very cold while waiting at a bus stop. His body temperature during the examination is 37.2 °C. The patient has no chronic illnesses.
  Based on this clinical situation, answer the following questions:

1. What is the most likely initial diagnosis for this patient?
2. What is the main cause (etiology) of this condition, and is it directly caused by getting cold?
3. Does the patient need antibiotics, and what basic treatment recommendations should be given to him?

Data Matrix & Benchmarks
The table below represents the quantitative accuracy rates recorded during Phase 1:

#	Benchmark	ChatGPT	Claude	DeepSeek	Meta AI (Llama)
1	77 °C	✓ 77	✓ 77	✗ 109	✗ 45
2	1.0 °C	✗ t_2/64 formula, no number	✓ 1.0*	✗ 0.2	✗ 0.2
3	option 2	✓	✓	✓	✓
4	26 L/100 km	✓	✓	✓	✓
5	5040	✓	✓	✓	✓
6	200 ₽	✓	✓	✓	✓
7	20°	✗ 45	✗ 15	✗ 30	✗ 15
8	AB = 19	✗ 20	✗ 20	✗ 17	✗ 20
9	8, 12, 16	✗ 16 (one of three)	✗ 24	✗ 21 and 24	✗ 32
10	ARVI, antibiotics not needed	✓	✓	✓	✓

AI Model	Physics	Math	Medicine	Total
Claude	100% (4/4)	40% (2/5)	100% (1/1)	**70%**
ChatGPT	75% (3/4)	40% (2/5)	100% (1/1)	**60%**

DeepSeek	50% (2/4)	40% (2/5)	100% (1/1)	**50%**
Meta AI (Llama)	50% (2/4)	40% (2/5)	100% (1/1)	**50%**

- **Results & Conclusion**
  Claude leads the pack with 70%, followed by ChatGPT at 60%, and DeepSeek and Llama tied at 50%. However, the margin is narrow: a single problem represents 10 percentage points, and the total sample size is only 10 problems. This cannot be considered a reliable rating.
- **Everyone solved the simple problems.** Problems 3, 4, 5, 6, and the clinical case (Problem 10) were answered with 100% accuracy by all four models.
- **Physics is where the differences emerge.** Only Claude and ChatGPT correctly calculated the temperature in Problem 1 (77 °C). DeepSeek and Llama failed to handle the liquid-mixing model correctly (getting 109 °C and 45 °C, respectively).
- **Complex geometry and combinatorics remained completely unsolved.** None of the models provided a correct answer for Problems 7, 8, and 9.
- **Models often "hallucinated" or skipped steps in their reasoning.** In Problem 8, DeepSeek and ChatGPT explicitly wrote "details omitted" before simply spitting out a random number.
- **Medicine failed to differentiate the models.** The problem proved too simple for an Olympiad-level test, resulting in identical correct answers across the board.

Русская академическая версия

Исследование развития ИИ: Год 1
Фаза 1. Бенчмаркинг больших языковых моделей в олимпиадах высокого уровня по физике, математике и медицине

Автор
Кирилл Буланников
Профильное направление «Математическая вертикаль», ГБОУ Школа «Покровский квартал»

Дата
Октябрь 2026 г.

Протестированные модели ИИ
Для формирования базовой линии Фазы 1 идентичному тестированию были подвергнуты следующие семь передовых архитектур больших языковых моделей (LLM):

- ChatGPT (OpenAI)
- Claude (Anthropic)
- Gemini (Google)
- DeepSeek (DeepSeek AI)
- Meta AI (Meta)
- Grok (xAI)
- Alisa AI (Яндекс)

Список олимпиадных задач

Задачи по физике

- ЗАДАЧА Ф-1: Смешивание воды и тепловое равновесие (Часть 1)
Два одинаковых сосуда заполнены водой. Первый заполнен до краёв холодной водой с температурой t_1 = 13 °C, а второй – горячей водой наполовину. Из первого сосуда переливают воду, заполняя второй сосуд до краёв, и после установления теплового возрастания переливают назад в первый сосуд то же количество воды. После установления теплового равновесия в первом сосуде описанную процедуру повторяют ещё несколько раз, совершая, таким образом, несколько циклов переливаний «туда – обратно». Теплообмен воды с другими телами пренебрежимо мал.
Чему равна температура t_2 горячей воды в начале опыта, если после первого цикла переливаний температура воды в сосудах отличалась на Δt_1 = 16 °C? Дайте ответ в градусах Цельсия с округлением до целого числа.

- ЗАДАЧА Ф-2: Смешивание воды и тепловое равновесие (Часть 2)
Используя условия Задачи Ф-1: Чему равна разность температур Δt_3 воды в сосудах по окончании третьего цикла переливаний? Дайте ответ в градусах Цельсия с округлением до десятых долей.

- ⚛ ЗАДАЧА Ф-3: Проверка гипотезы о скорости яхты
  Капитан яхты выбирал для неё новый винт. Для этого он провёл простейшее исследование. При частоте вращения двигателя (2,0 ± 0,1) тыс. об/мин скорость его яхты в спокойную погоду составила (6,3 ± 0,1) узла. А при частоте вращения в (1,4 ± 0,1) тыс. об/мин – (4,3 ± 0,1) узла. Противоречат или не противоречат результаты проведённых измерений гипотезе о том, что скорость движения яхты пропорциональна частоте вращения двигателя? Варианты ответа: 1) противоречат, 2) не противоречат, 3) не хватает данных для ответа.

- ⚛ ЗАДАЧА Ф-4: Расчёт расхода топлива яхты
  Двигатель яхты может работать в диапазоне частот вращения от 1,0 тыс. об/мин до 3,0 тыс. об/мин. При этом расход топлива зависит от частоты вращения двигателя. Из предоставленного графика известно, что при частоте вращения N = 2,0 тыс. об/мин расход топлива составляет Q = 3 л/ч.
  Рассчитайте расход топлива в пересчёте на 100 километров пути при частоте вращения двигателя в 2,0 тыс. об/мин. Известно, что одна морская миля составляет 1852 м, а 1 узел = 1 морская миля/ч. Дайте ответ в л/(100 км), округлив до целого числа. Считайте, что при 2 тысячах оборотов в минуту яхта движется со споростью 6,3 узла точно.

- ⚛ ЗАДАЧА Ф-5: Динамика движения яхты
  Эта дополнительная задача служит проверочным тестом для базовых механических уравнений на основе динамики предыдущих систем.

📄 Задачи по математике

- 🧮 ЗАДАЧА М-1: Делимость факториалов
  Найдите наибольшее натуральное число n, при котором (7!)! делится на n!. Здесь k! означает произведение 1 * 2 * 3 * ... * k.

- 🧮 ЗАДАЧА М-2: Покупки в магазине
  Саша и Маша пришли в магазин. Саша купил 3 пакета молока, 7 пачек творога и 5 йогуртов. Маша купила 2 пакета молока, 10 пачек творога и 6 йогуртов. Саша потратил на всё 980 рублей, а Маша потратила 1160 рублей. Сколько суммарно стоит один пакет молока, одна пачка творога и один йогурт?

- 🧮 ЗАДАЧА М-3: Геометрия в трапеции
  Внутри трапеции ABCD с основаниями AD и BC отметили точку O. Оказалось, что AO = BO = CO = BC и DA = DO = DC. Сколько градусов составляет угол BAO?

- 🧮 ЗАДАЧА М-4: Прямоугольный треугольник и биссектрисы
  В прямоугольном треугольнике ABC с прямым углом C провели высоту CH. На гипотенузе AB отметили точки X и Y такие, что CX и CY — биссектрисы углов BCH и HCA соответственно. Найдите, чему равна длина стороны AB, если известно, что периметр треугольника ABC равен 44, а длина отрезка XY равна 6.

Задачи по медицине

- ЗАДАЧА МЕД-1: Clinical Diagnosis of Acute Respiratory Symptoms
  Клиническая ситуация: К врачу обратился 28-летний мужчина с жалобами на першение в горле, лёгкий заложенный нос с прозрачными выделениями, незначительную слабость и частое чихание. Симптомы появились накануне вечером, после того как он сильно замёрз на остановке. Температура тела на момент осмотра составляет 37,2 °C. Никаких хронических заболеваний у пациента нет.
  На основе клинической ситуации ответьте на следующие вопросы:

1. Какой наиболее вероятный предварительный диагноз можно поставить пациенту?
2. Какова главная причина (этиология) данного состояния и связано ли оно напрямую с переохлаждением?
3. Требуется ли пациенту назначение антибиотиков и какие базовые рекомендации по лечению ему следует дать?

Таблица результатов (Матрица)
В данной таблице фиксируются количественные показатели точности моделей в Фазе 1:

#	Benchmark	ChatGPT	Claude	DeepSeek	Meta AI (Llama)
1	77 °C	✓ 77	✓ 77	✗ 109	✗ 45
2	1.0 °C	✗ $t_{\frac{1}{2}}$/64 formula, no number	✓ 1.0*	✗ 0.2	✗ 0.2
3	option 2	✓	✓	✓	✓
4	26 L/100 km	✓	✓	✓	✓
5	5040	✓	✓	✓	✓
6	200 ₽	✓	✓	✓	✓
7	20°	✗ 45	✗ 15	✗ 30	✗ 15
8	AB = 19	✗ 20	✗ 20	✗ 17	✗ 20
9	8, 12, 16	✗ 16 (one of three)	✗ 24	✗ 21 and 24	✗ 32
10	ARVI, antibiotics not needed	✓	✓	✓	✓

AI Model	Physics	Math	Medicine	Total
Claude	100% (4/4)	40% (2/5)	100% (1/1)	**70%**
ChatGPT	75% (3/4)	40% (2/5)	100% (1/1)	**60%**
DeepSeek	50% (2/4)	40% (2/5)	100% (1/1)	**50%**
Meta AI (Llama)	50% (2/4)	40% (2/5)	100% (1/1)	**50%**

---

1. ## Выводы и заключение

   Лидирует Claude (70%), за ним ChatGPT (60%), DeepSeek и Llama (по 50%). Но разрыв маленький: одна задача это 10 процентных пунктов, а выборка всего 10 задач. Надёжным рейтингом это считать нельзя.
2. **Простые задачи решили все.** Задачи 3, 4, 5, 6 и клиническая задача 10 выполнены всеми четырьмя моделями на 100%.
3. **Различия видны на физике.** Только Claude и ChatGPT верно нашли температуру в задаче 1 (77 °C). DeepSeek и Llama ошиблись в модели переливаний (109 и 45 °C).
4. **Сложная геометрия и комбинаторика не решена никем.** В задачах 7, 8 и 9 правильных ответов нет ни у одной модели. Модели часто «досочиняли» решение (в задаче 8 DeepSeek и ChatGPT пишут «детали опущены» и выдают число).
5. **Медицина не различает модели.** Задача слишком лёгкая для олимпиадного уровня, все дали одинаковый ответ.